



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería de Sistemas
Facultad de Ingeniería Mecánica Eléctrica, Electrónica y
Sistemas



RIESGO AGROCLIMÁTICO POR HELADAS EN LA REGIÓN PUNO

**Dashboard interactivo para el análisis y la visualización de datos orientado a
la toma de decisiones**

Informe técnico presentado para la asignatura de Visualización de Datos

Docente:	Ing. Edwin Edgar Mestas Yucra
Asignatura:	Visualización de Datos
Código:	SIS328
Semestre:	2026-I
Ciclo:	X
Integrantes:	Aracayo Mamani, Jhon Marco Canaza Paucara, Juan Diego Luque Pacheco, Angie Tatiana
Fuente:	ERA5-Land / ERA5 (ECMWF–Copernicus), con validación MERRA-2 (NASA POWER)
Periodo:	1 de enero de 2015 al 31 de diciembre de 2024

Índice

1. Resumen	1
2. Introducción	1
3. Planteamiento del problema	2
4. Objetivos	2
4.1. Objetivo general	2
4.2. Objetivos específicos	2
5. Descripción y procedencia del dataset	3
5.1. Fuentes y cobertura	3
5.2. Estructura y cumplimiento de los requisitos	4
6. Metodología de limpieza y transformación	4
6.1. Pipeline reproducible	4
6.2. Conversión de unidades y control de calidad	5
6.3. Definiciones operativas e índice de riesgo	5
6.4. Validación cruzada	6
7. Diseño del dashboard	6
7.1. Arquitectura por capas	6
7.2. Diseño visual y accesibilidad	6
7.3. Vistas, filtros e interacción	6
8. Resultados e interpretación	7
8.1. P1: situación general del riesgo	7
8.2. P2: distribución provincial y ciclo anual	8
8.3. P3: evolución y tendencia	10
8.4. P4: concentración territorial del riesgo	11
8.5. P5: relación entre variables agroclimáticas	12
8.6. P6: factores latentes, agrupamientos, anomalías y explicación	13
9. Capturas del dashboard	14
10. Conclusiones	18
11. Recomendaciones	18
12. Limitaciones	19
13. Referencias	19
A. Enlaces y reproducibilidad	21
B. Bitácora íntegra del pipeline	21

C. Diccionario completo de variables	22
D. Aportes del equipo	24

Índice de figuras

1.	Ranking provincial de días con helada meteorológica. La longitud de la barra codifica el conteo acumulado bajo un periodo común para todas las provincias.	8
2.	Ciclo anual promedio. Los paneles separados evitan un doble eje y muestran que el máximo de heladas coincide con la estación de menor precipitación.	9
3.	Calendario provincia-mes de incidencia de heladas. Las celdas muestran el porcentaje de observaciones bajo 0 °C.	10
4.	Promedio anual de días con helada por provincia y ajuste lineal OLS.	10
5.	Correlaciones de Pearson entre variables seleccionadas. La escala divergente separa asociaciones negativas y positivas.	12
6.	Varianza individual y acumulada del PCA aplicado a doce variables estandarizadas.	13
7.	Comparación de temperatura mínima entre ERA5-Land y MERRA-2. La línea discontinua representa concordancia perfecta.	14
8.	Vista general: identificación, filtros, KPI y síntesis del periodo activo.	15
9.	Análisis descriptivo: distribuciones, comparación territorial y evolución temporal.	15
10.	Análisis multidimensional: correlaciones, PCA, grupos, anomalías y modelo explicativo.	16
11.	Análisis geográfico: localización provincial, perfil altitudinal y calendario territorial.	16
12.	Conclusiones: respuestas a P1–P6, recomendaciones y limitaciones.	17
13.	Metodología y datos: fuentes, bitácora ETL, diccionario y descargas.	17

Índice de cuadros

1.	Preguntas analíticas y método principal de respuesta	3
2.	Comparación de las fuentes climáticas utilizadas	3
3.	Verificación de los requisitos oficiales del conjunto de datos	4
4.	Etapas del pipeline de preparación de datos	4
5.	Conversiones de unidad aplicadas antes del análisis	5
6.	Responsabilidad de las capas del proyecto	6
7.	Módulos del dashboard y propósito analítico	7
8.	Distribución de la intensidad de helada meteorológica	7
9.	Indicadores térmicos por provincia, 2015–2024	8
10.	Contrastes de tendencia sobre los días anuales de helada por provincia	11
11.	Diccionario completo del dataset analítico	22
12.	Responsabilidades y contribuciones de los integrantes	24

1. Resumen

Se desarrolló un dashboard interactivo para caracterizar la frecuencia, intensidad, estacionalidad y distribución territorial de las heladas en las trece provincias de la región Puno. La unidad de análisis es la observación diaria por capital provincial. El dataset integra 47 489 registros del periodo 2015–2024 y 52 variables analíticas. La fuente primaria es ERA5-Land / ERA5 del Servicio de Cambio Climático de Copernicus, consultada mediante Open-Meteo a una resolución aproximada de 9 km; MERRA-2, obtenida de NASA POWER, se empleó únicamente para validación cruzada.

El proceso incluyó normalización del esquema, conversión de unidades, validación física, control de duplicados y continuidad temporal, integración de fuentes y construcción de 23 variables derivadas. La tasa de helada meteorológica (temperatura mínima $\leq 0^{\circ}\text{C}$) fue 16,05 %, mientras que la tasa bajo el umbral agronómico ($\leq 3^{\circ}\text{C}$) alcanzó 39,75 %. El riesgo no fue homogéneo: Carabaya acumuló 1,126 días con helada, frente a ninguno en Sandía y Yunguyo. Julio concentró la mayor incidencia mensual (49,93 %). Los contrastes OLS y Mann–Kendall no identificaron una tendencia significativa en la ventana de diez años. El análisis multivariante mostró que la primera componente explica 48,20 % de la varianza y que 5 componentes alcanzan el 90 %. Los resultados se presentan mediante indicadores, filtros, visualizaciones y explicaciones orientadas a la planificación agraria diferenciada por territorio.

Palabras clave: helada, riesgo agroclimático, Puno, ERA5-Land, dashboard, visualización de datos, análisis multivariante.

Abstract

An interactive dashboard was developed to characterize the frequency, severity, seasonality, and spatial distribution of frost across the thirteen provinces of Puno, Peru. The unit of analysis is a daily observation at each provincial capital. The analytical dataset contains 47 489 records and 52 variables for 2015–2024. ERA5-Land / ERA5, provided by the Copernicus Climate Change Service and accessed through Open-Meteo, is the primary source; MERRA-2 from NASA POWER is used only for cross-validation. Meteorological frost occurred in 16,05 % of records, whereas the agronomic threshold yielded 39,75 %. Frost exposure varied markedly among provinces and peaked in July. Neither OLS nor Mann–Kendall detected a statistically significant monotonic trend over the ten-year window. PCA, clustering, anomaly detection, and an explanatory Random Forest complement the descriptive views. The resulting system turns reproducible climate data into indicators and evidence for territorially targeted agricultural decisions.

Keywords: frost, agroclimatic risk, Puno, ERA5-Land, dashboard, data visualization, multivariate analysis.

2. Introducción

La helada ocurre cuando la temperatura del aire próximo a la superficie desciende hasta un nivel capaz de afectar tejidos vegetales, agua disponible y condiciones de manejo pecuario. En el altiplano, su efecto depende tanto de la temperatura mínima como de la estación, la altitud, la humedad, la nubosidad, el viento y la exposición territorial. Por ello, un único promedio regional puede ocultar contrastes que son decisivos para la programación de siembras, la focalización del seguro agrario y la preparación de alertas.

Los reanálisis climáticos permiten estudiar el fenómeno de forma continua allí donde la red de estaciones es escasa. ERA5-Land combina modelación física y asimilación de observaciones para producir series espacial y temporalmente coherentes (Muñoz-Sabater et al., 2021). Su uso no sustituye la medición en superficie, pero ofrece una base reproducible para comparar territorios

bajo una definición común. La visualización interactiva añade una segunda capa de valor: permite cambiar umbrales, periodos y unidades territoriales sin perder la trazabilidad del cálculo.

Este proyecto adopta el principio de que cada gráfico debe responder una pregunta. La vista general resume la magnitud del problema; el análisis descriptivo muestra distribuciones y evolución; el módulo multidimensional examina relaciones, factores latentes, grupos y anomalías; la vista geográfica sitúa el riesgo; y la sección final explicita hallazgos, recomendaciones y límites. La metodología combina estadística descriptiva, inferencia, aprendizaje automático explicativo y criterios de diseño visual.

3. Planteamiento del problema

Las heladas constituyen uno de los peligros agroclimáticos más relevantes para los sistemas productivos altoandinos. Sin embargo, los registros disponibles suelen estar dispersos en servicios especializados y expresados mediante variables y unidades que no son inmediatamente utilizables por quienes toman decisiones. Esta distancia entre dato y acción favorece dos simplificaciones: tratar a Puno como un territorio climáticamente homogéneo y usar exclusivamente el umbral meteorológico de 0 °C, aun cuando muchos cultivos presentan daño potencial por debajo de 3 °C.

La pregunta central es: *¿cómo se distribuyen en el tiempo y en el territorio la frecuencia y la intensidad de las heladas en las trece provincias de Puno, y qué factores climáticos se asocian con ellas durante 2015–2024?* El problema exige una solución que integre adquisición, depuración, análisis y comunicación. Mostrar datos sin interpretación no es suficiente: el usuario debe poder identificar la ventana crítica, comparar provincias, evaluar relaciones y descargar el subconjunto que sustenta cada lectura.

La relevancia práctica se observa en la diferencia entre umbrales: se contabilizaron 7 620 observaciones bajo el umbral meteorológico y 18 877 bajo el agronómico. Planificar sólo con el primer criterio reduce el fenómeno visible a cerca de una fracción 1/2,48 del riesgo térmico potencial para el cultivo.

4. Objetivos

4.1. Objetivo general

Diseñar, implementar y documentar un dashboard interactivo que transforme datos agroclimáticos verificables en indicadores, visualizaciones y conclusiones sobre el riesgo por heladas en la región Puno durante 2015–2024, con énfasis en la toma de decisiones territorialmente diferenciada.

4.2. Objetivos específicos

1. Construir un dataset diario, trazable y sin discontinuidades para las trece capitales provinciales, documentando fuente, unidades y controles de calidad.
2. Medir la frecuencia, intensidad, estacionalidad y variación interanual de las heladas meteorológicas y agronómicas.
3. Comparar provincias, pisos ecológicos y zonas agroecológicas para identificar concentraciones territoriales del riesgo.
4. Evaluar asociaciones entre temperatura mínima, altitud, humedad, nubosidad, precipitación, radiación y viento mediante métodos lineales y no paramétricos.

5. Aplicar PCA, K-Means, agrupamiento jerárquico, detección de anomalías y Random Forest como técnicas complementarias, declarando su alcance y sus límites.

Cuadro 1. Preguntas analíticas y método principal de respuesta

Código	Pregunta	Método principal
P1	¿Cuál es la situación general del riesgo por heladas?	KPI, resumen ejecutivo y perfil anual.
P2	¿Cómo se distribuye la ocurrencia e intensidad entre provincias y meses?	Barras, histograma, caja y calendario térmico.
P3	¿Existe una evolución o tendencia significativa?	Serie anual, OLS, Mann–Kendall y pendiente de Sen.
P4	¿Qué provincias concentran el mayor y menor riesgo?	Ranking, mapa interactivo y comparación territorial.
P5	¿Qué relación existe entre variables ambientales y temperatura mínima?	Pearson, Spearman, dispersión y VIF.
P6	¿Existen factores latentes, zonas homogéneas y días atípicos?	PCA, K-Means, Ward, Isolation Forest y Random Forest.

5. Descripción y procedencia del dataset

5.1. Fuentes y cobertura

La fuente primaria es el reanálisis ERA5-Land / ERA5 del European Centre for Medium-Range Weather Forecasts y el Copernicus Climate Change Service, consultado mediante la API histórica de Open-Meteo con el modelo `era5_seamless` y agregación en la zona horaria `America/Lima`. La fuente secundaria es MERRA-2, distribuida por NASA POWER. Ambas cubren las mismas fechas y capitales; la segunda no alimenta los indicadores, sino que permite evaluar si la señal binaria de helada depende de un único producto.

Cuadro 2. Comparación de las fuentes climáticas utilizadas

Criterio	Fuente primaria	Fuente secundaria
Producto	ERA5-Land / ERA5	MERRA-2
Institución	ECMWF–Copernicus C3S; acceso Open-Meteo	NASA Langley Research Center; NASA POWER
Resolución nominal	0,1°, aproximadamente 9 km	0,5° × 0,625°, aproximadamente 55–65 km
Granularidad	Diaria por capital provincial	Diaria por capital provincial
Función analítica	Fuente de todos los indicadores y modelos	Validación cruzada independiente
Periodo	2015-01-01 a 2024-12-31	2015-01-01 a 2024-12-31

La elección de la malla más fina responde a una prueba previa. Con MERRA-2, Chucuito, El Collao y Yunguyo recibían series idénticas al caer en una misma celda; lo mismo ocurría con Azángaro, Huancané y San Antonio de Putina. Además, la celda asignaba 3,668 msnm a Sandia, cuya capital se ubica alrededor de 2,170–2,300 msnm. Un ranking elaborado sobre esa malla habría confundido la geometría del producto con diferencias provinciales. ERA5-Land distingue los trece puntos, con elevaciones de malla entre 2,294 y 4,321 msnm.

5.2. Estructura y cumplimiento de los requisitos

La clave natural es el par (**provincia, fecha**). Existen 3 653 días por provincia, 13 provincias y, por multiplicación, 47 489 registros. Las 52 columnas incluyen variables temporales, territoriales, térmicas, hídricas, de radiación y viento, indicadores derivados y campos de control de calidad.

Cuadro 3. Verificación de los requisitos oficiales del conjunto de datos

Requisito	Estado	Evidencia
Al menos 500 registros	Cumple	47 489 observaciones.
Al menos seis variables	Cumple	52 variables documentadas.
Variables numéricas y categóricas	Cumple	31 numéricas, 14 categóricas y 6 booleanas; fecha temporal.
Dimensión temporal o geográfica	Cumple	Fecha diaria, provincia, latitud, longitud y altitud.
Fuente verificable y citada	Cumple	ERA5-Land / ERA5 y MERRA-2, con DOI o portal institucional.
Necesidad de limpieza o integración	Cumple	Pipeline de 13 etapas, cuatro conversiones e integración de 47,489 pares.
Sin información sensible	Cumple	Sólo variables ambientales agregadas por punto de malla.

6. Metodología de limpieza y transformación

6.1. Pipeline reproducible

La ingeniería de datos se implementó como funciones independientes de Streamlit. El mismo pipeline puede invocarse desde scripts, pruebas o cuadernos, lo que reduce divergencias entre la aplicación y el informe. La Tabla 4 resume sus trece etapas.

Cuadro 4. Etapas del pipeline de preparación de datos

N.	Etapas	Operación y control
1	Normalización	Renombrado de 19 variables nativas y unificación de campos territoriales.
2	Fecha	Conversión de texto ISO a tipo temporal y orden cronológico.
3	Unidades	Conversión de viento, presión e insolación a unidades analíticas comunes.
4	Centinelas	Sustitución auditable de códigos de ausencia; no se encontraron –999.
5	Rangos físicos	Comprobación de límites plausibles en 19 variables; cero valores anulados.
6	Coherencia térmica	Validación de $\text{mínima} \leq \text{media} \leq \text{máxima}$; cero incoherencias.
7	Precipitación	Marcado, sin borrado, de acumulados superiores a 100 mm/día; un caso.
8	Unicidad	Eliminación de duplicados sobre provincia–fecha; cero duplicados.
9	Calendario	Reindexado a 3 653 días por provincia; cero fechas ausentes.

N.	Etapas	Operación y control
10	Imputación	Interpolación intraprovincial sólo cuando fuese necesaria; cero imputaciones.
11	Integración	Unión uno a uno con MERRA-2 y cálculo de concordancia.
12	Derivación	Generación de 23 campos temporales, territoriales y de riesgo.
13	Tipado	Categorías y flotantes de 32 bits; 6,8 MB de memoria analítica.

6.2. Conversión de unidades y control de calidad

Cuadro 5. Conversiones de unidad aplicadas antes del análisis

Variable	Unidad original	Unidad final
Velocidad del viento	km/h	m/s, factor 0,277778
Racha máxima	km/h	m/s, factor 0,277778
Presión superficial	hPa	kPa, factor 0,1
Duración de insolación	s	h, factor 0,000277778

La radiación solar requirió una revisión específica. El servicio entrega el acumulado en MJ/m²/día. Interpretarlo como kWh/m²/día y limitarlo al intervalo 0–12 habría invalidado 46,564 observaciones, que luego podrían haber sido rellenadas por interpolación sin que el error fuese visible. El rango correcto, 0–45 MJ/m²/día, no anuló ninguna observación. Este episodio demuestra que la validación debe basarse en la unidad declarada por el servicio y no sólo en el nombre del parámetro.

Se conservó un registro con precipitación superior a 100 mm el 10 de agosto de 2015 y se marcó mediante `precipitacion_sospechosa`. La decisión evita eliminar un episodio posiblemente real y permite incluirlo o excluirlo con trazabilidad. El dataset final no contiene ausentes, duplicados ni fechas faltantes.

6.3. Definiciones operativas e índice de riesgo

Se definió helada meteorológica cuando $T_{\min} \leq 0^\circ\text{C}$ y helada agronómica cuando $T_{\min} \leq 3^\circ\text{C}$. La intensidad meteorológica se dividió en ligera (0 a -2°C), moderada (-2 a -4°C), severa (-4 a -6°C) y extrema (menor que -6°C).

El índice diario de riesgo de helada, en escala 0–100, combina cuatro mecanismos. Todos se normalizan con límites fijos y se recortan a $[0, 1]$:

$$D = \text{clip}\left(\frac{3 - T_{\min}}{12}, 0, 1\right), \quad C = \text{clip}\left(1 - \frac{N}{100}, 0, 1\right), \quad (1)$$

$$S = \text{clip}\left(\frac{100 - H}{60}, 0, 1\right), \quad V = \text{clip}\left(1 - \frac{v}{8}, 0, 1\right), \quad (2)$$

$$IRH = 100(0,45D + 0,25C + 0,20S + 0,10V), \quad (3)$$

donde N es nubosidad porcentual, H humedad relativa y v velocidad del viento en m/s. El déficit térmico recibe el mayor peso por representar el efecto directo; el cielo despejado, la sequedad y la calma describen condiciones favorables a la pérdida radiativa. Los límites fijos

hacen comparables dos selecciones filtradas. Los pesos son explícitos, pero no están calibrados contra pérdidas de rendimiento y por ello el índice no debe interpretarse como probabilidad de daño.

6.4. Validación cruzada

Los 47 489 pares ERA5-Land-MERRA-2 presentaron correlación $r = 0,611$, sesgo medio de $1,29\text{ }^{\circ}\text{C}$ y error absoluto medio de $2,54\text{ }^{\circ}\text{C}$. La clasificación binaria de helada coincidió en $83,06\%$. La concordancia respalda la señal general; la correlación moderada es coherente con la diferencia entre mallas de 9 y 55–65 km y obliga a interpretar con más confianza los patrones relativos que los valores puntuales.

7. Diseño del dashboard

7.1. Arquitectura por capas

La aplicación separa configuración, dominio, componentes y vistas. Esta decisión reduce el acoplamiento y permite probar los cálculos sin iniciar un servidor web.

Cuadro 6. Responsabilidad de las capas del proyecto

Directorio	Responsabilidad
config/	Rutas, metadatos, fuentes, umbrales, provincias, preguntas e identidad visual.
utils/	Adquisición, limpieza, filtros, métricas, estadística, modelos y exportación.
components/	Tarjetas, KPI, gráficos, barra lateral, navegación y descargas reutilizables.
pages/	Orquestación de las vistas; consume funciones de dominio sin duplicar cálculos.
scripts/	Flujo reproducible de descarga, procesamiento, resultados y capturas.
data/	Originales, dataset analítico, diccionario y metadatos de trazabilidad.
report/	Fuente LaTeX, resultados calculados y figuras del informe.

7.2. Diseño visual y accesibilidad

La interfaz usa una identidad pastel de naranja y azul en superficies amplias. Los trazos, marcadores y textos emplean versiones más oscuras para conservar contraste. La paleta no se seleccionó únicamente por preferencia estética: se optimizó en el espacio OKLCH bajo restricciones de claridad, croma, contraste con el fondo y separación cromática simulada para protanopía y deuteranopía según el modelo de Machado, Oliveira y Fernandes (2009).

Se aplicaron tres reglas. Primero, una categoría nominal comparada en barras mantiene un color común y usa posición y longitud como canales principales; el color destaca sólo una referencia. Segundo, las variables continuas usan escalas secuenciales y las cantidades con signo, escalas divergentes centradas en cero. Tercero, toda codificación cromática dispone de un canal de relevo mediante etiquetas, marcadores o tabla descargable. La dispersión y los mapas limitan a cuatro series cuando cualquier par de marcas puede quedar adyacente.

7.3. Vistas, filtros e interacción

La vista general y cinco páginas analíticas conservan un estado compartido. Los ocho controles incluyen rango temporal, provincias, pisos ecológicos, temporadas, temperatura mínima, altitud, umbral de helada y exclusión de registros sospechosos. Al modificar un control se recalculan KPI, gráficos, tablas e interpretaciones. La selección persiste al navegar, lo que constituye filtrado cruzado real.

Cuadro 7. Módulos del dashboard y propósito analítico

Vista	Contenido y propósito
Vista general	Ocho KPI, resumen ejecutivo, hallazgos automáticos, riesgo, ranking y ciclo anual.
Análisis descriptivo	Distribuciones, comparación provincial, estacionalidad y tendencia P2–P4.
Análisis multidimensional	Correlación, PCA, agrupamientos, anomalías y modelo explicativo P5–P6.
Análisis geográfico	Mapa interactivo, perfil altitudinal, cuencas, pisos y efecto circunlacustre.
Conclusiones	Respuesta explícita a P1–P6, recomendaciones, límites, fuentes y trazabilidad.
Metodología y datos	Fuentes, requisitos, bitácora, unidades, diccionario, validación y descargas.

El inventario supera las seis visualizaciones obligatorias: barras para ranking; líneas para evolución; histograma y caja para distribución térmica; dispersión para relaciones; mapa de calor estacional; mapa geográfico; scree plot, biplot y proyección 3D para PCA; dendrograma para Ward; cronología de anomalías; curvas ROC y precisión–recobrado para el clasificador. Cada gráfico se acompaña de descripción, patrón, hallazgo, decisión y limitación. Los datos filtrados pueden descargarse en CSV con codificación UTF-8 BOM y en un libro Excel de varias hojas.

8. Resultados e interpretación

Los resultados de esta sección se recalcularon desde `data/datos_limpios.csv` con semilla 42 y se almacenaron en `report/resultados.json`. Las figuras se generan con `report/generar_figuras_informe.py`; no son transcripciones manuales.

8.1. P1: situación general del riesgo

De 47 489 observaciones, 7 620 cumplieron el umbral meteorológico, equivalente a 16,05 %. El umbral agronómico identificó 18 877 observaciones (39,75 %), 2,48 veces la incidencia meteorológica. La temperatura mínima media fue 3,79 °C y la mínima absoluta, -9,1 °C en Carabaya el 23 de julio de 2018. El índice compuesto promedió 31,71 puntos.

Cuadro 8. Distribución de la intensidad de helada meteorológica

Clase	Observaciones	Proporción del total
Sin helada	39,869	83,95 %
Ligera	5,180	10,91 %
Moderada	2,090	4,40 %
Severa	320	0,67 %
Extrema	30	0,06 %

La mayoría de los eventos fue ligera o moderada; aun así, 350 observaciones alcanzaron intensidad severa o extrema. La decisión operativa no debe basarse sólo en el promedio: los extremos y el umbral agronómico cambian el volumen de días que requieren prevención.

8.2. P2: distribución provincial y ciclo anual




Figura 1. Ranking provincial de días con helada meteorológica. La longitud de la barra codifica el conteo acumulado bajo un periodo común para todas las provincias.

Carabaya encabezó el ranking con 1,126 días (30,82 % de sus observaciones), seguida por San Antonio de Putina con 976 y El Collao con 962. Yunguyo y Sandia no presentaron días bajo 0°C en el punto de malla analizado. Esta ausencia no implica que toda la provincia esté libre de heladas: cada territorio se representa mediante una sola capital.

Cuadro 9. Indicadores térmicos por provincia, 2015–2024

Provincia	Altitud (m)	Días	Tasa (%)	$T_{\text{mín}}$ media ($^{\circ}\text{C}$)
Carabaya	4,321	1,126	30,82	0,96
San Antonio de Putina	3,867	976	26,72	2,24
El Collao	3,835	962	26,33	2,85
San Román	3,828	930	25,46	2,53
Azángaro	3,861	830	22,72	2,45
Lampa	3,868	799	21,87	2,72
Puno	3,819	683	18,70	3,41
Melgar	3,912	460	12,59	2,82
Chucuito	3,872	406	11,11	4,10
Huancané	3,838	365	9,99	3,93
Moho	4,043	83	2,27	4,05
Sandia	2,294	0	0,00	10,10
Yunguyo	3,825	0	0,00	7,15




Figura 2. Ciclo anual promedio. Los paneles separados evitan un doble eje y muestran que el máximo de heladas coincide con la estación de menor precipitación.

La incidencia fue menor que 1 % entre enero y marzo y alcanzó 47,44 % en junio y 49,93 % en julio. En esos meses la precipitación diaria media descendió a 0,79 y 0,63 mm, respectivamente. El patrón es consistente con heladas radiativas bajo cielos más despejados y aire seco; la visualización identifica mayo–agosto como la ventana prioritaria para preparación, sin afirmar que precipitación y helada mantengan una relación causal aislada.




Figura 3. Calendario provincia–mes de incidencia de heladas. Las celdas muestran el porcentaje de observaciones bajo 0 °C.

8.3. P3: evolución y tendencia




Figura 4. Promedio anual de días con helada por provincia y ajuste lineal OLS.

La tasa anual osciló entre 11,14 % en 2024 y 18,23 % en 2015. OLS estimó -1,37 días por provincia y año, pero el intervalo de confianza al 95 % incluyó cero y $p = 0,132$ ($R^2 = 0,260$). Mann–Kendall produjo $\tau = -0,422$, pendiente de Sen -1,00 y $p = 0,107$. Ambos métodos coinciden: no existe evidencia suficiente de tendencia monotonía al nivel 0,05.

Cuadro 10. Contrastes de tendencia sobre los días anuales de helada por provincia

Método	Pendiente	Estadístico	p	n	Lectura
OLS	-1,37 días/año	$R^2 = 0,260$	0,132	10	No significativa
Mann–Kendall/Sen	-1,00 días/año	$\tau = -0,422$	0,107	10	Sin tendencia

La caída observada en 2024 no se interpreta como cambio climático. Diez años son insuficientes para establecer una normal climática y la variabilidad interanual puede dominar el ajuste. El resultado sí permite afirmar que el periodo estudiado no ofrece evidencia estadística de una reducción sostenida.

8.4. P4: concentración territorial del riesgo

El contraste más informativo aparece entre Yunguyo y San Román. Sus elevaciones de malla son casi idénticas (3,825 y 3,828 msnm), pero acumularon 0 y 930 días con helada. En el conjunto de trece provincias, la relación entre altitud y tasa fue positiva ($r = 0,485$), aunque no significativa al 5 % ($p = 0,093$). En el nivel diario, la correlación entre altitud y temperatura mínima fue $r = -0,551$.

Las observaciones de la zona “Altiplano circunlacustre” presentaron una tasa de 11,40 %, frente a 20,03 % en el resto. La diferencia es consistente con el efecto termorregulador del lago Titicaca, cuya inercia térmica atenúa el enfriamiento nocturno. No obstante, el diseño observacional y la representación por un punto no permiten aislar causalmente el efecto del lago frente a topografía, cobertura y circulación local. La decisión prudente es evitar zonificaciones basadas sólo en altitud y combinar la posición circunlacustre con evidencia local.

8.5. P5: relación entre variables agroclimáticas




Figura 5. Correlaciones de Pearson entre variables seleccionadas. La escala divergente separa asociaciones negativas y positivas.

La temperatura mínima mostró las asociaciones lineales más altas con temperatura del suelo ($r = 0,658$), nubosidad ($r = 0,561$), altitud ($r = -0,551$) y humedad relativa ($r = 0,536$). La precipitación alcanzó $r = 0,437$ y la radiación solar $r = -0,105$. Spearman confirmó el orden general, con $\rho = 0,679$ para temperatura del suelo y $\rho = 0,557$ para precipitación. Dado el tamaño muestral, magnitudes pequeñas pueden resultar estadísticamente detectables; por eso la interpretación prioriza tamaño y mecanismo, no sólo el valor p .

La asociación positiva entre humedad, nubosidad y mínima diaria es físicamente coherente con la reducción de la pérdida radiativa nocturna. Sin embargo, una correlación bivariada no separa estación, provincia ni colinealidad. El dashboard ofrece Pearson y Spearman, valores p y VIF, y usa la dispersión para reconocer no linealidad y grupos territoriales.

8.6. P6: factores latentes, agrupamientos, anomalías y explicación




Figura 6. Varianza individual y acumulada del PCA aplicado a doce variables estandarizadas.

El PCA se ejecutó después de estandarizar las doce variables; de otro modo la altitud, medida en miles de metros, dominaría por escala. CP1 explicó 48,20 % y estuvo definida principalmente por humedad relativa y punto de rocío con cargas positivas, frente a oscilación térmica negativa: un eje humedad–amplitud. CP2 explicó 20,46 % y concentró temperatura del suelo, evapotranspiración, radiación y temperatura mínima: un eje térmico- energético. Las dos primeras sumaron 68,66 %; fueron necesarias 5 componentes para superar 90 %, por lo que reducir todo el sistema a dos dimensiones facilita la visualización pero no conserva toda la información.

K-Means seleccionó $k = 3$ al maximizar la silueta entre dos y cuatro grupos. La silueta fue 0,306, clasificada como estructura débil. Los perfiles separaron un régimen seco con helada frecuente (34,4 % y riesgo medio 47,44), uno húmedo con baja incidencia (3,2 %) y el régimen cálido de Sandia (0 %). Los grupos son una síntesis exploratoria, no fronteras agroclimáticas definitivas.

Isolation Forest marcó 475 observaciones, aproximadamente 1 % del total. Las más extremas combinaron altas temperaturas, lluvia intensa, humedad cercana a saturación, nubosidad y baja radiación, especialmente en Sandia. Esta lectura ilustra la ventaja del criterio multivariante: una observación puede ser atípica por combinación aunque ninguna variable aislada supere un umbral fijo.

El Random Forest explicativo, entrenado con partición cronológica, alcanzó AUC ROC 0,990, precisión media 0,948, exactitud 95,23 %, sensibilidad 94,47 % y precisión positiva 78,16 %. Se excluyeron temperatura mínima, déficit térmico e índice de riesgo porque definen directa o algebraicamente el objetivo. La importancia por permutación situó primero a oscilación térmica, punto de rocío y temperatura del suelo. El desempeño no convierte el modelo en pronóstico operativo: no se ha validado prospectivamente ni contra estaciones, y su propósito es ordenar variables asociadas bajo el periodo disponible.




Figura 7. Comparación de temperatura mínima entre ERA5-Land y MERRA-2. La línea discontinua representa concordancia perfecta.

9. Capturas del dashboard

Las capturas documentan la traducción de los resultados a una interfaz navegable. Se generan automáticamente con un navegador sin interfaz, resolución 1680×1050 y factor de escala 2; por tanto, constituyen evidencia reproducible y no una composición manual. Si una imagen no está disponible durante una compilación intermedia, el documento mantiene el espacio identificado sin interrumpir el resto del informe.



Figura 8. Vista general: identificación, filtros, KPI y síntesis del periodo activo.

La primera vista debe permitir responder P1 sin navegar: explicita denominador, umbral, periodo y provincia crítica. Las variaciones se colorean por efecto favorable o adverso, no sólo por signo numérico.



Figura 9. Análisis descriptivo: distribuciones, comparación territorial y evolución temporal.

El módulo descriptivo vincula cada gráfico con una tabla y una interpretación. Las distribuciones muestran la forma y los extremos; el ranking conserva el mismo periodo para evitar comparaciones con denominadores distintos.




Figura 10. Análisis multidimensional: correlaciones, PCA, grupos, anomalías y modelo explicativo.

La vista avanzada separa exploración, diagnóstico y desempeño. Los controles limitan el número de series y mantienen visibles la estandarización, la semilla y los criterios de selección de componentes o grupos.



Figura 11. Análisis geográfico: localización provincial, perfil altitudinal y calendario territorial.

El mapa permite ubicar el riesgo, pero el ranking y las etiquetas aportan la comparación cuantitativa que el área y el color por sí solos no garantizan. La vista declara que cada provincia está representada por su capital.



Figura 12. Conclusiones: respuestas a P1–P6, recomendaciones y limitaciones.

Esta página evita que el usuario deba inferir conclusiones sólo a partir de gráficos. Cada respuesta cita la magnitud relevante, enlaza el método y separa resultado, decisión y limitación.



Figura 13. Metodología y datos: fuentes, bitácora ETL, diccionario y descargas.

La trazabilidad muestra el origen de los datos, las conversiones, los controles y la validación. Los archivos original, limpio, diccionario y metadatos se mantienen separados para que el resultado pueda auditarse.

10. Conclusiones

1. La incidencia depende del umbral: 16,05 % de las observaciones cumplió la definición meteorológica y 39,75 % la agronómica. Usar sólo 0 °C subrepresenta el conjunto de días térmicamente relevantes para el cultivo por un factor de 2,48.
2. El riesgo no es homogéneo. Carabaya acumuló 1,126 días con helada, mientras Sandia y Yunguyo no registraron ninguno en el punto analizado. Una medida regional uniforme oculta diferencias de más de treinta puntos porcentuales.
3. La ventana crítica se concentra entre mayo y agosto; julio alcanzó 49,93 %. Este calendario permite anticipar la asignación de medidas de protección, alertas y asistencia técnica.
4. La altitud es relevante pero insuficiente. Yunguyo y San Román tienen elevaciones de malla casi idénticas y resultados opuestos. La menor tasa circunlacustre es consistente con la inercia térmica del Titicaca y exige incorporar ubicación y microclima a la zonificación.
5. No se detectó una tendencia monotonía significativa durante 2015–2024: OLS produjo $p = 0,132$ y Mann–Kendall $p = 0,107$. El hallazgo correcto es ausencia de evidencia en esta ventana, no demostración de estabilidad climática de largo plazo.
6. La estructura multivariante no se reduce sin pérdida a dos ejes. CP1 y CP2 explican 68,66 %, pero se requieren 5 componentes para 90 %. La proyección 2D es útil para explorar, no para sustituir las variables originales.
7. K-Means obtuvo tres perfiles con silueta 0,306. La separación débil obliga a usar los grupos como tipología exploratoria y no como límites administrativos o ecológicos rígidos.
8. La validación cruzada logró 83,06 % en la clasificación de helada. La señal general es reproducible entre productos, aunque las diferencias de resolución justifican cautela en valores absolutos.
9. El producto final es reproducible: conserva original, limpio, diccionario, metadatos, semilla y código de generación. El dashboard no sólo muestra figuras; conecta filtros, resultados, interpretación y descarga del subconjunto analizado.

11. Recomendaciones

Gobierno Regional de Puno.

Priorizar seguro agrario, cobertizos, riego preventivo y asistencia en Carabaya, San Antonio de Putina, El Collao y San Román, sin asumir que una misma intervención produce igual beneficio en toda la región.

Dirección Regional Agraria.

Elaborar calendarios de siembra y protocolos de alerta por provincia. Intensificar la vigilancia entre mayo y agosto y complementar temperatura prevista con humedad, nubosidad y oscilación térmica.

Productores y organizaciones.

Usar el umbral agronómico de 3 °C como aviso temprano para cultivos sensibles; combinarlo con conocimiento local, estado fenológico y disponibilidad de riego o cobertura.

SENAMHI y academia.

Densificar estaciones en fondos de valle, laderas y zonas con mayor dis-

crepancia entre reanálisis. Comparar prospectivamente el índice con observaciones de superficie y eventos reportados.

Equipo de desarrollo.

Mantener pruebas automáticas sobre filtros, KPI, agregaciones y modelos; versionar el esquema del dataset y recalcular `resultados.json` antes de cada publicación.

Investigación futura.

Integrar rendimiento y pérdidas económicas, cobertura de suelo, pendiente, distancia al lago y pronósticos de corto plazo. Calibrar los pesos del índice contra daño observado y evaluar validación espacial fuera de las capitales.

12. Limitaciones

1. La malla primaria de aproximadamente 9 km suaviza extremos locales y no resuelve fondos de valle ni laderas donde la inversión térmica puede intensificarse.
2. Los datos son reanálisis, es decir, combinación de modelo y observaciones asimiladas; no equivalen a una estación meteorológica de superficie.
3. Cada provincia se representa mediante la coordenada de su capital. La variabilidad interna de Carabaya, Sandia y otros territorios topográficamente complejos queda submuestreada.
4. Diez años permiten estudiar variabilidad interanual, pero no establecer normales climáticas de treinta años ni atribuir tendencias al cambio climático.
5. MERRA-2 posee una malla más gruesa. Su correlación moderada con ERA5-Land refleja escalas distintas y limita la comparación de valores diarios puntuales.
6. Un registro de precipitación superior a 100 mm fue conservado y marcado; puede influir en análisis sensibles a extremos, aunque es excluible mediante filtro.
7. No se dispone de rendimiento agrícola, especie, variedad ni fase fenológica; por ello no se cuantifica daño físico o económico.
8. El índice de riesgo usa pesos expertos y límites fijos no calibrados contra pérdidas observadas. Es una herramienta comparativa, no una probabilidad validada de daño.
9. El Random Forest es explicativo y fue evaluado dentro del mismo periodo. La alta AUC no demuestra capacidad de pronóstico futuro ni transferencia a otros lugares.
10. Las asociaciones y la comparación circunlacustre son observacionales. No permiten inferir causalidad aislada ni separar todos los mecanismos topográficos y atmosféricos.

13. Referencias

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Cleveland, W. S., y McGill, R. (1984). Graphical perception: Theory, experimentation, and application to the development of graphical methods. *Journal of the American Statistical Association*, 79(387), 531–554.

- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.a ed.). Lawrence Erlbaum Associates.
- Gelaro, R., et al. (2017). The Modern-Era Retrospective Analysis for Research and Applications, Version 2 (MERRA-2). *Journal of Climate*, 30(14), 5419–5454. <https://doi.org/10.1175/JCLI-D-16-0758.1>
- Hersbach, H., et al. (2020). The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730), 1999–2049. <https://doi.org/10.1002/qj.3803>
- Iglewicz, B., y Hoaglin, D. C. (1993). *How to detect and handle outliers*. ASQC Quality Press.
- Jolliffe, I. T., y Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065). <https://doi.org/10.1098/rsta.2015.0202>
- Kendall, M. G. (1975). *Rank correlation methods* (4.a ed.). Charles Griffin.
- Liu, F. T., Ting, K. M., y Zhou, Z.-H. (2008). Isolation forest. En *2008 Eighth IEEE International Conference on Data Mining* (pp. 413–422). <https://doi.org/10.1109/ICDM.2008.17>
- Machado, G. M., Oliveira, M. M., y Fernandes, L. A. F. (2009). A physiologically-based model for simulation of color vision deficiency. *IEEE Transactions on Visualization and Computer Graphics*, 15(6), 1291–1298.
- Mann, H. B. (1945). Nonparametric tests against trend. *Econometrica*, 13(3), 245–259.
- Muñoz-Sabater, J., et al. (2021). ERA5-Land: A state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data*, 13(9), 4349–4383. <https://doi.org/10.5194/essd-13-4349-2021>
- Munzner, T. (2014). *Visualization analysis and design*. CRC Press.
- NASA Langley Research Center. (2025). *NASA Prediction Of Worldwide Energy Resources (POWER) Project: Daily agroclimatology data* (Version 2.9.6) [Conjunto de datos]. <https://power.larc.nasa.gov/>
- Pulgar Vidal, J. (1981). *Geografía del Perú: Las ocho regiones naturales* (8.a ed.). Editorial Universo.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- Sen, P. K. (1968). Estimates of the regression coefficient based on Kendall’s tau. *Journal of the American Statistical Association*, 63(324), 1379–1389.
- Servicio Nacional de Meteorología e Hidrología del Perú. (2024). *Monitoreo y pronóstico de heladas*. <https://www.senamhi.gob.pe/>
- Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.
- Universidad Nacional del Altiplano. (2026). *Proyecto final: Dashboard interactivo de visualización de datos* [Consigna del curso SIS328].

A. Enlaces y reproducibilidad

Repositorio. <https://github.com/jhonaracayo/dashboard-heladas-puno>

Dashboard publicado. <https://dashboard-heladas-puno.streamlit.app>

Fuente primaria. <https://archive-api.open-meteo.com/v1/archive>

Fuente secundaria. <https://power.larc.nasa.gov/api/temporal/daily/point>

Los comandos mínimos de reproducción, ejecutados desde la raíz del repositorio, son:

```
python scripts/01_descargar_datos.py
python scripts/02_procesar_datos.py
python report/generar_figuras_informe.py
streamlit run app.py
```

La descarga no debe repetirse para reproducir el informe mientras se conserven los originales. La semilla global es 42. El archivo `requirements.txt` fija las versiones mínimas verificadas; `metadata.json` registra cobertura, estructura y cada etapa del pipeline.

B. Bitácora íntegra del pipeline

1. Inicio del pipeline: 47,489 filas $\times$ 32 columnas de entrada.
2. Normalización del esquema: 19 variables nativas del servicio se renombraron a nombres semánticos en español y se unificó la nomenclatura geográfica (latitud, longitud, altitud).
3. La fecha llegaba como cadena de texto ISO; se convirtió a tipo temporal para habilitar filtros por rango, agregaciones cronológicas y cálculo de tendencias.
4. Homogeneización de unidades en 4 variables: velocidad_viento km/h $\rightarrow$ m/s ($\times 0.277778$); racha_viento_maxima km/h $\rightarrow$ m/s ($\times 0.277778$); presion_superficie hPa $\rightarrow$ kPa ($\times 0.1$); horas_sol s $\rightarrow$ h ($\times 0.00027778$).
5. No se hallaron valores centinela (-999.0); el servicio codifica la ausencia como nulo JSON, ya interpretado como ausente en la carga.
6. Validación de rangos físicos sobre 19 variables: 0 observaciones fuera de los límites admisibles fueron anuladas.
7. Verificación de coherencia térmica (mínima $\leq$ media $\leq$ máxima): 0 filas incoherentes; en ellas la media se recalculó como punto medio de los extremos observados.
8. Control de calidad de la precipitación: 1 acumulados diarios superiores a 100 mm se marcaron como sospechosos y se conservaron sin modificar. El episodio dominante es 2015-08-10, con 1 provincia(s) afectada(s) el mismo día; el dato permanece disponible y trazable para el análisis de anomalías.
9. Control de unicidad sobre la clave natural (provincia, fecha): 0 registros duplicados eliminados.
10. Reindexado al calendario diario completo (3,653 días $\times$ 13 provincias = 47,489 filas esperadas): 0 días ausentes materializados.

11. Imputación por provincia (interpolación lineal bidireccional en variables continuas; relleno con cero en las de precipitación): 0 valores completados; 0 ausentes residuales.
12. Integración de la fuente secundaria (MERRA-2 / NASA POWER) por la clave (provincia, fecha): 47,489 filas emparejadas. Correlación de la temperatura mínima entre fuentes $r = 0.611$; sesgo medio $+1.29$ °C; concordancia en la clasificación binaria de helada 83.1 %.
13. Transformación: se generaron 23 variables derivadas (descomposición temporal, caracterización territorial por piso ecológico, indicadores de helada e índice compuesto de riesgo agroclimático).
14. Optimización de tipos (categóricos y punto flotante de 32 bits): el dataset analítico ocupa 6.8 MB en memoria.
15. Pipeline finalizado: 47,489 filas $\times$ 52 columnas en el dataset analítico.

C. Diccionario completo de variables

El diccionario siguiente se genera desde `data/diccionario_datos.csv`. Para cada campo se indica etiqueta, unidad, procedencia y definición operativa; por ello funciona como contrato semántico entre adquisición, análisis y visualización.

Cuadro 11. Diccionario completo del dataset analítico

Variable	Etiqueta	Unidad	Origen	Descripción
fecha	Fecha	—	original	Día de observación (resolución diaria).
anio	Año	—	derivada	Año calendario de la observación.
mes	Mes	—	derivada	Número de mes (1–12).
mes_nombre	Nombre del mes	—	derivada	Mes en texto, ordenado cronológicamente.
mes_abrev	Mes abrev	—	derivada	Variable auxiliar del modelo de datos.
trimestre	Trimestre	—	derivada	Trimestre calendario (T1–T4).
dia_anio	Día del año	—	derivada	Día juliano (1–366).
semana_anio	Semana anio	—	derivada	Variable auxiliar del modelo de datos.
anio_mes	Anio mes	—	derivada	Variable auxiliar del modelo de datos.
temporada	Temporada	—	derivada	Lluviosa, Transición o Seca.
campania_agricola	Campaña agrícola	—	derivada	Campaña MIDAGRI de agosto a julio.
provincia	Provincia	—	original	Provincia de la región Puno.
capital	Capital provincial	—	original	Capital que define el punto de consulta.
latitud	Latitud	°	original	Latitud decimal del punto de malla.
longitud	Longitud	°	original	Longitud decimal del punto de malla.
altitud	Altitud	msnm	original	Elevación del punto reportada por la API.
cuenca	Vertiente hidrográfica	—	derivada	Titicaca (endorreica) o Amazonas.
zona_agroecologica	Zona agroecológica	—	derivada	Caracterización agroecológica provincial.

Continúa en la página siguiente

Continuación de la tabla 11

Variable	Etiqueta	Unidad	Origen	Descripción
piso_ ecologico	Piso ecológico	—	derivada	Piso altitudinal según Pulgar Vidal (1981).
temperatura_ minima	Temperatura mínima	°C	original	Temperatura mínima diaria del aire a 2 m; variable central del estudio.
temperatura_ media	Temperatura media	°C	original	Temperatura del aire a 2 m, promedio diario.
temperatura_ maxima	Temperatura máxima	°C	original	Temperatura máxima diaria del aire a 2 m.
oscilacion_ termica	Oscilación térmica	°C	derivada	Diferencia entre temperatura máxima y mínima.
temperatura_ suelo	Temperatura del suelo	°C	original	Temperatura media del suelo entre 0 y 7 cm de profundidad.
punto_ rocio	Punto de rocío	°C	original	Temperatura de rocío media a 2 m.
humedad_ relativa	Humedad relativa	%	original	Humedad relativa media diaria a 2 m.
deficit_ presion_ vapor	Déficit de presión de vapor	kPa	derivada	VPD calculado con la ecuación de Tetens.
deficit_ presion_ vapor_ maximo	Déficit de presión de vapor máximo	kPa	original	Valor máximo diario del déficit de presión de vapor.
precipitacion	Precipitación	mm	original	Precipitación total diaria (lluvia y equivalente en agua de nieve).
lluvia	Lluvia	mm	original	Fracción líquida de la precipitación diaria.
nevada	Nevada	cm	original	Espesor de nieve acumulada en el día.
horas_ precipitacion	Horas con precipitación	h	original	Número de horas del día con precipitación registrada.
humedad_ suelo	Humedad del suelo	m ³ /m ³	original	Contenido volumétrico de agua del suelo entre 0 y 7 cm.
evapotranspiracion	Evapotranspiración de referencia	mm	original	ET ₀ diaria calculada con el método FAO-56 Penman-Monteith.
radiacion_ solar	Radiación solar	MJ/m ²	original	Irradiancia global horizontal acumulada en el día.
horas_ sol	Horas de sol	h	original	Duración de la insolación directa.
nubosidad	Nubosidad	%	original	Cobertura nubosa media diaria; determinante de la helada de radiación.
velocidad_ viento	Velocidad del viento	m/s	original	Velocidad media del viento a 10 m.
racha_ viento_ maxima	Racha máxima de viento	m/s	original	Velocidad máxima del viento a 10 m.
presion_ superficie	Presión superficial	kPa	original	Presión atmosférica media en superficie.
helada	Helada	—	derivada	Verdadero si la temperatura mínima ≤ 0 °C.
helada_ agronomica	Helada agronómica	—	derivada	Verdadero si la temperatura mínima ≤ 3 °C.
intensidad_ helada	Intensidad de helada	—	derivada	Clasificación ordinal de severidad del evento.
deficit_ termico	Déficit térmico	°C	derivada	Grados por debajo del umbral agronómico (0 si no aplica).
indice_ riesgo_ helada	Índice de riesgo de helada	0–100	derivada	Índice compuesto de riesgo agroclimático diario.
nivel_ riesgo	Nivel de riesgo	—	derivada	Clasificación ordinal del índice de riesgo en cinco niveles.

Continúa en la página siguiente

Continuación de la tabla 11

Variable	Etiqueta	Unidad	Origen	Descripción
dia_lluvia	Día con lluvia	—	derivada	Verdadero si la precipitación ≥ 1 mm.
dia_nevada	Día nevada	—	derivada	Variable auxiliar del modelo de datos.
precipitacion_sospechosa	Precipitación implausible	—	derivada	Marca de control de calidad: acumulado diario >100 mm, atribuible al reanálisis.
temperatura_minima_merra2	Temperatura mínima (MERRA-2)	°C	original	Temperatura mínima de la fuente secundaria, para validación cruzada.
helada_merra2	Helada según MERRA-2	—	derivada	Ocurrencia de helada según la fuente secundaria independiente.
fuelle	Fuente	—	derivada	Variable auxiliar del modelo de datos.

D. Aportes del equipo

Cuadro 12. Responsabilidades y contribuciones de los integrantes

Integrante	Rol principal	Aportes
Aracayo Mamani, Jhon Marco	Arquitectura de software y dashboard	Estructura por capas, integración de Streamlit, navegación, estado de filtros y componentes re-utilizables.
Canaza Paucara, Juan Diego	Ingeniería de datos y análisis multivariante	Adquisición, pipeline de limpieza, integración MERRA-2, PCA, agrupamiento, anomalías y reproducibilidad.
Luque Pacheco, Angie Tatiana	Visualización, estadística y redacción	Diseño visual accesible, selección y justificación de gráficos, análisis de tendencia, interpretación e informe técnico.

La participación se distribuye por especialidad, pero los tres integrantes comparten la responsabilidad de explicar el problema, la preparación de datos, el código, las visualizaciones y las conclusiones durante la sustentación.